МИФИ

Теория многоагентных систем

ОТЧЁТ

Лабораторная работа 4

Диверсионный анализ и оценка надёжности многоагентной системы

Выполнил студент
группы Б24-517
Яковлев Иван

Москва
2026

Лабораторная работа 4

Диверсионный анализ и оценка надёжности многоагентной системы

1 Цель и исследуемая конфигурация

Цель — выявить отказы складской MAC при неблагоприятных воздействиях, ввести защитные ограничения и повторно оценить устойчивость на одинаковых входах. Исследуется контрольный контур из ЛР 1: назначения, сообщения о завершении, общий ресурс и монитор.

Для изоляции причин отказа используется малая конфигурация: D, два одинаковых рабочих агента W0 и W1, станция S ёмкости один и монитор M. Есть 12 FIFO-заказов; длительность работы U{5…9}, обслуживание 2 такта. Новое задание выдаётся свободному агенту. Модель времени и назначения упрощена относительно ЛР 2; прямое сравнение абсолютных времён между работами некорректно.

2 Модель угроз и границы доверия

Доверенными считаются диспетчер, монитор, станция, реестр и физическое свидетельство среды. Рабочий агент может отправить ложное сообщение, не выполнять работу, попытаться изменить назначение или передать задачу. Внешнее средство может быть временно недоступно. Канал сохраняет идентичность источника в пределах симуляции.

У исходного режима отсутствуют проверки полномочий и версий, идемпотентность завершения, тайм-аут аренды и повторное подключение к отказавшему средству. Эти недостатки заданы явно как уязвимая исходная политика. Улучшенный режим использует тот же сценарий и параметры, включая затраты на работу; меняются только правила защиты.

Не моделируются сетевые подписи, криптографические атаки, компрометация D/S/M, одновременная комбинация нескольких воздействий и LLM-инъекция естественного языка. Подмена цели реализована изменением локального поведения агента, поэтому результаты не являются оценкой защиты языковой модели от prompt injection.

3 Условия успешного запуска

Успех требует физического выполнения всех 12 заказов, точного совпадения множества принятых завершений с физически выполненными, отсутствия двойного начисления и запрещённых изменений. Незавершение к 180-му такту — отказ живости, даже если инварианты безопасности не нарушены.

4 Набор неблагоприятных сценариев

Сценарий	Способ воздействия	Ожидаемый дефект исходного режима
false_done	В такт 2 владелец заказа 0 отправляет DONE до работы и станции.	Учёт фиктивного выполнения и потеря заказа.
goal_hijack	В такт 2 агент заменяет локальную цель на удержание заказа; ready переносится далеко за горизонт.	Заказ зависает, один исполнитель выпадает.
tool_outage	Станция недоступна на [10,45); уже начатая операция завершается.	Первый неуспешный вызов фиксирует отказ без последующих попыток.
forged_assignment	W1 отправляет ASSIGN_OVERRIDE для заказа 0 и назначает незарегистрированного владельца intruder.	Нарушение полномочий и блокировка ресурса недопустимым владельцем.
delegation_cycle	От заказа 0 запускается повторяющаяся передача W0 → W1 → W0.	Циклическая передача вместо выполнения; рост сообщений.
stale_cancel	W1 отправляет CANCEL заказа 0 с версией 0 при текущей версии 1.	Чужая устаревшая команда отменяет действующий заказ.
replay_done	Первое действительное DONE повторяется без изменения содержания.	Повторное начисление при единственном физическом выполнении.
clean	Контрольный запуск без воздействия.	Проверка отсутствия ложного отказа защиты.

Все управляющие воздействия проходят через тот же обработчик receive, который принимает штатный DONE. Это исполняемые изменения состояния, а не заранее назначенные итоговые числа. Подмена цели меняет локальное время готовности; недоступность средства меняет разрешённость физической операции.

Сценарии выбраны из классов методички: недостоверное сообщение, агент с другой целью, недоступность средства, некорректная передача полномочий, цикл и противоречивые команды. Повтор сообщения дополнительно проверяет учёт ровно одного результата. Контроль clean служит базой для оценки ложных срабатываний.

5 Введённые защитные ограничения

Правило	Условие применения и реакция
Физическое доказательство	DONE принимается, только если заказ есть в физическом журнале среды после завершения станции.
Связь с назначением	Владелец, version и lease должны совпадать с реестром; аренда не просрочена. Некорректные сообщения отклоняются до изменения состояния.
Идемпотентность	Повтор DONE для принятого заказа отклоняется без повторного начисления.
Минимальные полномочия	Рабочий агент не может переназначать и делегировать заказ. Переназначение выполняется D после отзыва старого владения.
Версия команды	Отмена должна исходить от D и иметь версию строго выше текущей. Чужая или старая CANCEL отклоняется.
Контроль аренды	Аренда 20 тактов. При просрочке работы M изолирует владельца, увеличивает версию и возвращает заказ в очередь. Подтверждённое ожидание станции не штрафуется.
Повтор вызова средства	После наблюдаемого сбоя — повтор каждые 5 тактов. Аренда ожидающим ресурс продлевается; перед GRANT она должна покрывать весь слот.
Физическая ёмкость	S выдаёт GRANT только при отсутствии активного слота. Новое обслуживание не перекрывает старое.

В штатной малой конфигурации 20 тактов превышают максимальные 9 тактов работы, 2 собственного обслуживания и до 2 ожидания конкурирующего слота. Поэтому тайм-аут отделяет заданное зависание от нормального исполнения. Это обоснование относится к двум рабочим и одному текущему заказу на агента; для большого n порог надо пересчитать.

Проверка пути и числа переходов предусмотрена в обработчике делегирования, но в текущей защищённой политике рабочее делегирование полностью запрещено раньше неё. Поэтому испытание цикла подтверждает эффективность запрета полномочий, а не отдельно эффективность TTL или проверки повторной вершины.

Защитные отклонения записываются как REJECT_INVALID с reason. Для отказа средства используются TOOL_UNAVAILABLE, LEASE_EXTEND, LEASE_RENEWED и TOOL_RECOVERED. Карантин и новая версия исключают продолжение старого владения в моделируемом контуре.

6 Методика и основные результаты

Выполнены 8 сценариев × 30 seed × 2 режима = 480 запусков, из них 420 с неблагоприятным воздействием. В каждой паре режимов совпадают трудоёмкости заказов и точка инъекции. Горизонт 180 тактов; при принятии 12 завершений цикл заканчивается раньше, затем результат проверяется по независимому физическому журналу.

F — число физических завершений; S — успех по всем критериям; B — сохранение безопасности и согласованности учёта. В столбцах долей приведены проценты запусков «без защиты / с защитой». Отсутствие прогресса может сохранить B, поэтому B не заменяет S.

Сценарий	F без	F с	S % без/с	B % без/с
Без воздействия	12,00	12,00	100 / 100	100 / 100
Ложный DONE	11,00	12,00	0 / 100	0 / 100
Подмена цели	11,00	12,00	0 / 100	100 / 100
Отказ станции	1,83	12,00	0 / 100	100 / 100
Чужое назначение	0,43	12,00	0 / 100	0 / 100
Цикл передачи	11,00	12,00	0 / 100	0 / 100
Старая отмена	11,00	12,00	0 / 100	0 / 100
Повтор DONE	12,00	12,00	0 / 100	0 / 100

Интерпретация отказов

Ложный DONE приводит к 11 физическим операциям при 12 принятых. Повтор DONE позволяет физически завершить всё, но число начислений становится 13; это нарушение учёта, а не отказ оборудования. Подмена цели сохраняет безопасность, но один заказ остаётся без результата. Цикл и устаревшая отмена оставляют 11 выполнений. Поддельное назначение блокирует очередь станции заказом с незарегистрированным владельцем; среднее число выполнений падает до 0,43.

В исходном режиме при отказе станции выполняется в среднем 1,83 заказа: после первого неуспешного обращения дальнейшие попытки отсутствуют. Защитный режим сохраняет очередь и продолжает работу после восстановления. Во всех 210 защищённых запусках с воздействием выполнены все 12 заказов с корректным учётом и без запрещённых изменений.

Наблюдаемые 30/30 успехов для каждого сценария не доказывают абсолютной надёжности. При независимых испытаниях и данном распределении входов односторонняя точная 95% нижняя граница вероятности успеха для отдельного сценария равна 0,05^(1/30) ≈ 0,905. Обобщать эту границу на неизвестные атаки нельзя.

7 Трассы диагностика и цена защиты

Сценарий	Такт остановки без	Такт остановки с	Сообщения без/с
Без воздействия	57,1 ± 1,2	57,1 ± 1,2	72,0 / 72,0
Ложный DONE	53,7 ± 1,1	57,1 ± 1,2	69,0 / 74,0
Подмена цели	180,0 ± 0,0	107,1 ± 2,0	69,0 / 76,0
Отказ станции	180,0 ± 0,0	88,4 ± 1,2	18,0 / 85,0
Чужое назначение	180,0 ± 0,0	57,1 ± 1,2	12,6 / 74,0
Цикл передачи	180,0 ± 0,0	57,1 ± 1,2	247,0 / 74,0
Старая отмена	180,0 ± 0,0	57,1 ± 1,2	69,0 / 74,0
Повтор DONE	57,1 ± 1,2	57,1 ± 1,2	73,0 / 74,0

± — половина 95% t-интервала среднего по 30 seed. Значение 180 в исходном режиме означает достижение горизонта с незавершённой работой, а не время успешного выполнения. Меньшее время исходного false_done — следствие потери физической операции и не является улучшением.

Разбор диагностических свидетельств

В трассе false_done при seed=0 в такт 2 поступает DONE для заказа 0 до физической операции. Защита возвращает REJECT_INVALID с причиной invalid_completion_evidence; корректное завершение того же заказа принимается в такт 10. В исходном режиме преждевременный DONE меняет состояние заказа на done и освобождает исполнителя; физического подтверждения в итоге нет.

При goal_hijack заказ 0 получает аренду до такта 20; в такт 21 монитор фиксирует lease_timeout, изолирует W0, увеличивает версию и возвращает задание в очередь W1. Время полного выполнения увеличивается до 107,1 ± 2,0 такта из-за работы оставшегося агента. В clean защита не создаёт ни одного отклонения, а время и число сообщений совпадают с исходным режимом.

Циклическая передача в исходной трассе порождает последовательность DELEGATE и 247 сообщений за запуск. Запрет рабочего делегирования обрывает её первым отказом. В replay_done причина duplicate_completion оставляет число начислений равным 12. Полные журналы, включая события станции и каждое отклонение, находятся в results/traces.

У защитного режима при отказе станции в среднем 85,0 сообщения против 72 в clean. Цена включает повторные обращения и продление аренды; восстановленное выполнение составляет 88,4 ± 1,2 такта. Проверки роли и учёта не имеют отдельно измеренной CPU-стоимости.

8 Выводы ограничения и повторение испытаний

Построены семь неблагоприятных сценариев и контроль без воздействия. Собраны полные трассы до и после введения защиты, выявлены нарушения полномочий, ложное и повторное завершение, потеря прогресса, цикл и необрабатываемый отказ средства. Защита устранила наблюдаемые отказы во всех проверенных парных запусках.

Существенно разделять безопасность и живость: зависание может не создавать запрещённых результатов, но задача остаётся нерешённой. Проверка физического свидетельства защищает учёт, аренда и повторное обращение восстанавливают прогресс. Отсутствие ложных срабатываний подтверждено только в чистой малой конфигурации.

Границы выводов

Базовый режим намеренно содержит явные уязвимые правила. Испытания показывают их последствия и эффект выбранных ограничений, а не сравнение со всеми промышленными системами. Доверенный физический журнал и подлинная идентичность канала — предпосылки модели. Если атакующий получает контроль над ними, текущие проверки могут быть обойдены.

Одновременные атаки, потеря и переупорядочение сетевых пакетов, компрометация центра, перезапуск процесса с восстановлением журнала и криптографическая защита не исследовались. Общая станция и диспетчер остаются точками отказа. Для следующего этапа целесообразно добавить независимые реплики контрольного журнала, смешанные воздействия и анализ порога аренды при росте n.

Проверка и воспроизведение

results/lab4_raw.csv содержит 480 исходных строк с physical, accepted, accounting, success, safe, ticks, messages, rejects и перечнем нарушений. summary.json содержит агрегаты; в results/traces сохранены парные журналы seed=0 для каждого сценария. Десять поведенческих тестов включают восстановление после воздействий, отказ от просроченных и некорректных сообщений, независимость защиты от названия сценария и проверку интервалов станции.

Приложения и воспроизведение

Исходники, данные и демонстрация опубликованы отдельно от отчёта в GitHub — материалы лабораторной работы 4. Каталог project содержит mas.py, experiments.py, test_mas.py, audit_results.py, README.md, автономную демонстрацию demo.html и результаты в results. Каждая папка лабораторной работы самодостаточна.

Репозиторий: github.com/Ivan-Yakovl/MAS_Course_Labs. Для просмотра скачайте и распакуйте материалы, затем откройте project/demo.html. Расчёт требует Python 3.10 или новее; точное воспроизведение проверено на Python 3.12.14. Команды приведены в README.md.

Источники

1. Рекомендации по выполнению лабораторных работ по курсу «Теория многоагентных систем». Лабораторные-МАС.pdf, с. 1–2.

2. Теория многоагентных систем. МАС. Лекция 2.pdf. Материалы курса.

3. Теория многоагентных систем. МАС. Лекция 3.pdf. Материалы курса.

4. Теория многоагентных систем. МАС. Лекция 5.pdf. Материалы курса.